HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN 1



BÁO CÁO BÀI TẬP LỚN

HỆ CƠ SỞ DỮ LIỆU ĐA PHƯƠNG TIỆN

Đề tài:

XÂY DỰNG HỆ CƠ SỞ DỮ LIỆU LƯU TRỮ VÀ TÌM KIẾM TIẾNG NHẠC CỤ BỘ GÕ

Lớp:	D23 - Lớp 04	
Nhóm:	07	
Giảng viên hướng dẫn:	TS. Nguyễn Đình Hóa	
Thành viên nhóm:	Hoàng Đình Kiên	B23DCCN457
	Khuất Quang Minh	B23DCCN547
	Nguyễn Hữu Việt	B23DCCN919

Hà Nội, tháng 10 năm 2026

Lời nói đầu

Cùng với sự phát triển của Internet và các thiết bị số, dữ liệu đa phương tiện như hình ảnh, âm thanh và video chiếm tỷ trọng ngày càng lớn trong dữ liệu được lưu trữ và khai thác. Khác với văn bản hay dữ liệu có cấu trúc, dữ liệu đa phương tiện khó tìm kiếm chỉ bằng tên tệp hoặc từ khóa; việc tìm kiếm cần dựa vào chính nội dung của dữ liệu. Vì vậy, một hệ cơ sở dữ liệu đa phương tiện phải giải quyết ba bài toán: biểu diễn nội dung bằng các đặc trưng, tổ chức lưu trữ các đặc trưng đó, và tìm kiếm theo độ tương đồng.

Trong bài tập lớn này, nhóm 07 thực hiện đề tài *Xây dựng hệ cơ sở dữ liệu lưu trữ và tìm kiếm tiếng nhạc cụ bộ gõ*. Âm thanh bộ gõ có những đặc điểm riêng: phần lớn nhạc cụ không có cao độ xác định, tiếng thường ngắn và năng lượng thay đổi nhanh theo thời gian. Do đó, các đặc trưng thường dùng cho tiếng nói hay âm nhạc có giai điệu cần được lựa chọn và giải thích cho phù hợp với loại âm thanh này.

Báo cáo trình bày kết quả của hai yêu cầu đầu tiên trong đề bài. Phần I mô tả bộ dữ liệu gồm 655 tệp âm thanh thuộc 13 nhóm nhạc cụ bộ gõ, cùng các điểm giống và khác nhau giữa tiếng của chúng. Phần II trình bày ba bộ đặc trưng dùng để nhận diện và tìm kiếm âm thanh tương đồng, kèm công thức, ý nghĩa và giá trị thông tin của từng đặc trưng. Các yêu cầu còn lại sẽ được xây dựng tiếp trên nền bộ dữ liệu và các bộ đặc trưng này.

Nhóm xin chân thành cảm ơn TS. Nguyễn Đình Hóa đã hướng dẫn và truyền đạt kiến thức trong suốt học phần. Do thời gian và kiến thức còn hạn chế, báo cáo khó tránh khỏi thiếu sót; nhóm rất mong nhận được ý kiến góp ý để hoàn thiện đề tài.

Hà Nội, tháng 10 năm 2026

Nhóm 07

Đề bài

Xây dựng hệ CSDL lưu trữ và tìm kiếm tiếng nhạc cụ bộ gõ.

1. Hãy xây dựng/sưu tầm một bộ dữ liệu âm thanh gồm ít nhất 500 files âm thanh của các nhạc cụ khác nhau thuộc bộ gõ. Các file âm thanh có độ dài phù hợp để chứa đựng đủ các đặc tính cần thiết để nhận diện tiếng nhạc cụ. Mỗi file âm thanh chỉ gồm tiếng của một nhạc cụ. Sinh viên tùy chọn định dạng file âm thanh để lưu trữ. Hãy mô tả các đặc điểm giống và khác nhau của tiếng các nhạc cụ trong các files trong bộ dữ liệu.
2. Hãy xây dựng một hoặc vài bộ đặc trưng để nhận diện âm thanh các nhạc cụ từ bộ dữ liệu đã thu thập. Các bộ thuộc tính phải bao gồm các đặc trưng giúp tìm sự tương đồng và tìm sự khác biệt giữa các âm thanh nhạc cụ trong các files dữ liệu. Hãy trình bày rõ về các đặc trưng đó và nêu giá trị thông tin của các đặc trưng được sử dụng.
3. Triển khai các thuật toán/công cụ trích rút các đặc trưng đã được xác định trong bước 2. Hãy xây dựng hệ CSDL để quản trị các đặc trưng âm thanh cho tất cả các files dữ liệu.
4. Triển khai hệ thống tìm kiếm âm thanh tương đồng với đầu vào là một file âm thanh mới về một nhạc cụ nào đó thuộc bộ gõ (nhạc cụ thuộc loại đã có và không có trong dữ liệu), đầu ra là 5 files âm thanh giống nhất, xếp thứ tự giảm dần về độ tương đồng nội dung với âm thanh đầu vào.
   a. Trình bày sơ đồ khối của hệ thống, chức năng của từng khối/module của hệ thống cùng các dữ liệu vào/ra cho từng khối. Mô tả quy trình thực hiện yêu cầu của đề bài.
   b. Hãy minh họa các kết quả trung gian (các giá trị đặc trưng, tính toán độ tương đồng) của quá trình truy vấn âm thanh.
   c. Đánh giá các kết quả đã đạt được.
5. Demo hệ thống.

Tóm tắt

Báo cáo trình bày bộ dữ liệu 655 tệp âm thanh thuộc 13 nhóm nhạc cụ bộ gõ. Các tệp được sưu tầm từ ba nguồn công khai: Freesound One-Shot Percussive Sounds, IDMT-SMT-Drums và University of Iowa Musical Instrument Samples. Mỗi tệp mang một nhãn nhạc cụ, kèm thông tin nguồn và thông số kỹ thuật. Bộ dữ liệu có cả tiếng gõ đơn lẻ và chuỗi nhiều lần gõ của cùng một nhạc cụ.

Trên bộ dữ liệu này, nhóm xây dựng ba bộ đặc trưng: **A gồm 21 thuộc tính thời gian và phổ**, **B gồm 39 thuộc tính MFCC** và **C gồm 60 thuộc tính kết hợp**. Các thuộc tính mô tả cách năng lượng phân bố theo thời gian và theo tần số: độ sáng, độ phân tán phổ, hình dạng bao phổ và mức biến đổi giữa các khung. Khoảng cách Euclid giữa các vector đã chuẩn hóa được dùng để lượng hóa mức giống và khác nhau giữa hai âm thanh.

Bảng 1: Đối chiếu nội dung đề bài với các phần của báo cáo.

Nội dung đề bài	Nội dung đáp ứng trong báo cáo
Ít nhất 500 tệp bộ gõ	655 tệp: nguồn, tổ chức và kiểm tra, Mục 1–2.
Độ dài phù hợp; một nhạc cụ mỗi tệp	Tiêu chí tuyển chọn, phân tích thời lượng và cách bảo đảm mỗi tệp chỉ có một nhạc cụ, Mục 2–3.
Tự chọn định dạng lưu trữ	WAV PCM 16-bit mono 16 kHz và lý do chọn, Mục 1.3.
Mô tả điểm giống và khác nhau	Phân loại 13 nhóm, phổ đồ, bảng mô tả và số đo trực tiếp, Mục 4–5.
Xây dựng một hoặc vài bộ đặc trưng	Quy trình và công thức của ba bộ A, B, C, Mục 6–10.
Đặc trưng tìm tương đồng và khác biệt	Phép đo khoảng cách và vai trò từng nhóm thuộc tính, Mục 10 và 12.
Giá trị thông tin của đặc trưng	Giải thích từng thuộc tính và kết quả định lượng trên dữ liệu, Mục 7–12.

MỤC LỤC

PHẦN I. YÊU CẦU 1: BỘ DỮ LIỆU ÂM THANH NHẠC CỤ BỘ GÕ **1**

1. Đối tượng, nguồn và định dạng dữ liệu 1
2. Tuyển chọn và kiểm soát chất lượng 2
3. Quy mô, thời lượng và độ phù hợp của tệp 3
4. Đặc điểm giống và khác nhau của tiếng nhạc cụ 4
5. So sánh định lượng tiếng nhạc cụ 6

PHẦN II. YÊU CẦU 2: CÁC BỘ ĐẶC TRƯNG NHẬN DIỆN ÂM THANH **9**

6. Quy trình biểu diễn âm thanh 9
7. Bộ A: năm thuộc tính thời gian 10
8. Bộ A: tám đại lượng phổ và cách tổng hợp 11
9. Bộ B: MFCC và thông tin về bao phổ 12
10. Bộ C và phép đo tương đồng 13
11. Giá trị thông tin thể hiện qua số liệu 13
12. Đóng góp của từng thuộc tính 15
13. Kết luận 17

PHỤ LỤC: DANH SÁCH THUỘC TÍNH CỦA CÁC BỘ ĐẶC TRƯNG **18**

TÀI LIỆU THAM KHẢO **19**

Phần I. Yêu cầu 1: Bộ dữ liệu âm thanh nhạc cụ bộ gõ

1. Đối tượng, nguồn và định dạng dữ liệu

1.1 Đối tượng, đơn vị dữ liệu và nhãn

Đối tượng là âm thanh của các nhạc cụ thuộc bộ gõ. Đơn vị lưu trữ và truy vấn là **một tệp WAV**; mỗi tệp mang đúng một nhãn thuộc 13 nhóm nhạc cụ. Nhãn chỉ loại nhạc cụ, không chỉ người chơi, cao độ hay kỹ thuật biểu diễn. Bảng 2 xếp 13 nhóm theo cách tạo âm; cách xếp này được dùng xuyên suốt khi so sánh.

Bảng 2: Phân loại 13 nhóm nhạc cụ trong bộ dữ liệu theo cách tạo âm.

Họ nhạc cụ	Nhãn trong bộ dữ liệu	Nguồn rung chính
Màng rung (membranophone)	kick, tom, conga, snare	Mặt trống; snare có thêm dây lò xo dưới mặt trống.
Tự thân vang, kim loại, không có cao độ xác định	hi-hat, cymbal, cowbell, agogo, tambourine	Thân kim loại; tambourine có các miếng chũm chọe nhỏ, một số mẫu có cả mặt màng.
Tự thân vang, gỗ, không có cao độ xác định	claves	Hai thanh gỗ gõ vào nhau.
Thanh gõ có cao độ xác định	marimba, xylophone, vibraphone	Thanh gỗ (marimba, xylophone) hoặc thanh kim loại (vibraphone) được lên dây theo nốt.

Cách gán nhãn. Nhãn ban đầu được gán theo quy tắc từ tên tệp và metadata của nguồn: với Freesound là tên và mô tả âm thanh (ví dụ "crash mute1.wav" thuộc nhóm cymbal); với IDMT là mã nhạc cụ trong tên tệp (`KD` cho kick, `SD` cho snare, `HH` cho hi-hat); với Iowa là tên nhạc cụ của thư viện. Nhãn sau đó được đối chiếu bằng mô hình CLAP như mô tả ở Mục 2.

"Một nhạc cụ" không đồng nghĩa với "một lần gõ". Một tệp hi-hat có nhiều lần đánh vẫn thuộc phạm vi nếu chỉ có tiếng hi-hat. Một nhạc cụ cũng có thể tạo nhiều thành phần âm, như phần thân tiếng trống và phần rè của dây lò xo ở snare. Đó là cấu tạo của cùng một nhạc cụ, khác với bản phối nhiều nhạc cụ.

1.2 Nguồn sưu tầm

Bảng 3: Ba nguồn dữ liệu và số tệp lấy từ mỗi nguồn.

Nguồn	Số tệp	Nhãn và cách xác minh
Freesound One-Shot Percussive Sounds [1]	513	11 nhóm (trừ marimba, vibraphone). Đối chiếu mã âm thanh, tên và người tải lên với metadata chính thức.
IDMT-SMT-Drums [2]	94	54 hi-hat, 32 kick, 8 snare; gồm 56 tệp thuộc phần training của IDMT và 38 rãnh tách riêng từng nhạc cụ (isolated tracks). Đối chiếu dạng sóng với gói chính thức.
University of Iowa MIS [3]	48	36 marimba, 12 vibraphone; đoạn trích từ các bản thu theo nốt của thư viện.
Tổng	**655**	Ba nguồn bổ sung độ đa dạng về nhạc cụ và điều kiện thu.

Freesound One-Shot Percussive Sounds là tập tiếng bộ gõ dạng một lần gõ (one-shot) đã được tác giả nguồn

sàng lọc [1]. IDMT cung cấp cả bản phối trống lẫn các phần riêng từng nhạc cụ; bộ dữ liệu chỉ lấy phần đơn nhạc cụ, không lấy bản phối [2]. Iowa tổ chức mẫu theo nhạc cụ, cao độ, cường độ và kỹ thuật chơi [3].

1.3 Định dạng và tổ chức lưu trữ

Toàn bộ tệp dùng WAV PCM 16-bit, một kênh, tần số lấy mẫu 16.000 Hz. WAV PCM là định dạng không nén, nên bản thân việc lưu trữ không làm mất thêm thông tin; định dạng này cũng dễ đọc lại và thuận tiện cho việc tính đặc trưng. Với các nguồn có tần số lấy mẫu cao hơn (ví dụ IDMT là 44,1 kHz), bước đưa về 16 kHz đã loại các thành phần trên tần số Nyquist 8 kHz. Mức này đủ để khảo sát phần lớn khác biệt trong tập hiện tại, nhưng làm mất một phần dải cao của tiếng kim loại như cymbal, hi-hat và tambourine.

Các tệp âm thanh được xếp vào 13 thư mục, mỗi thư mục ứng với một nhãn. Đi kèm là một bảng danh mục, mỗi tệp một dòng, ghi đường dẫn, nhãn, nguồn, người tải lên và mã băm SHA-256; các bảng kiểm kê ghi thời lượng và kết quả kiểm tra tín hiệu; các bảng đặc trưng lưu vector A, B, C của từng tệp, nối với danh mục qua mã tệp. Tên tệp và thông tin nguồn chỉ dùng để quản lý dữ liệu, **không được đưa vào vector đặc trưng**.

2. Tuyển chọn và kiểm soát chất lượng

2.1 Quy trình tuyển chọn

Cả **655 tệp** trong bộ dữ liệu đều đạt các tiêu chuẩn dưới đây. Đây là các ngưỡng do nhóm đặt ra để bảo đảm chất lượng, không phải ngưỡng bắt buộc trong đề bài.

1. **Kiểm kê và loại trùng:** đọc tệp, đối chiếu nhãn và đường dẫn, tính SHA-256 cho cả tệp và chuỗi mẫu PCM; không có hai tệp nào trùng nhau theo một trong hai mã này.
2. **Kiểm tra tín hiệu:** tệp đọc được, không rỗng, không có giá trị không xác định hoặc vô hạn; thời lượng ít nhất 0,1 s; vùng có tín hiệu ít nhất 0,05 s; đỉnh không thấp hơn -40 dBFS; biên độ mẫu đầu tiên không quá 10% đỉnh (tệp không bị cắt mất phần khởi âm); không bị cắt cụt ở cuối tệp và không bị cắt ngọn (clipping).
3. **Xác minh nguồn và nhãn:** mỗi tệp phải có thông tin nguồn và nhãn không còn xung đột phân loại. Với IDMT, so sánh dạng sóng sau khi đổi tần số lấy mẫu với tệp gốc trong gói chính thức (hệ số cosine trên 0,99 cho cả 94 tệp). Với Freesound, đối chiếu metadata chính thức.
4. **Sàng lọc hỗ trợ bằng CLAP:** CLAP (Contrastive Language–Audio Pretraining) là mô hình học chung không gian biểu diễn cho âm thanh và văn bản [4]. Nhóm dùng bản mô hình công khai do nhóm LAION phát hành để so sánh mỗi tệp với câu mô tả của 50 loại nhạc cụ bộ gõ. Tệp Freesound đạt chuẩn khi nhãn CLAP xếp hạng 1 trùng với nhãn lấy từ metadata. Tệp Iowa đạt chuẩn khi tên nhạc cụ của nguồn nằm trong ba nhãn CLAP xếp cao nhất. Tệp IDMT dựa chủ yếu vào bằng chứng dạng sóng của nguồn đơn nhạc cụ. Tệp mà CLAP cho thấy có dấu hiệu tiếng nói, nhạc phối hoặc hiệu ứng nhiễu không được đưa vào bộ dữ liệu.
5. **Cân đối nhóm và chốt phiên bản:** mỗi nhóm nhạc cụ có ít nhất 5 tệp đạt chuẩn. Toàn bộ thống kê, bộ chuẩn hóa và đặc trưng trong báo cáo được tính trên đúng 655 tệp này.

CLAP chỉ là công cụ hỗ trợ sàng lọc, không thuộc các bộ đặc trưng A, B, C ở Yêu cầu 2. Có 583/655 tệp được CLAP xếp đúng nhãn ở hạng 1 và 617/655 tệp có nhãn đúng trong ba hạng đầu. 72 tệp không được xếp đúng ở hạng 1 gồm 15 tệp Iowa, có nhãn đúng ở hạng 2 hoặc 3 nên đạt quy tắc ba hạng đầu, và 57 tệp IDMT, đạt chuẩn nhờ đối chiếu dạng sóng với gói gốc. Do tệp Freesound phải khớp với CLAP mới đạt chuẩn, phần dữ liệu này có thể nghiêng về những mẫu điển hình, dễ nhận diện của từng nhạc cụ.

2.2 Kết quả kiểm tra

Bảng 4: Kết quả kiểm tra trên phiên bản 655 tệp.

Hạng mục	Kết quả
Tệp đọc được / tổng số tệp	655 / 655
Số nhóm nhạc cụ	13
Số mã SHA-256 tệp / mã PCM khác nhau	655 / 655
Tệp còn cờ lỗi kỹ thuật theo quy trình tuyển chọn	0

Mã băm khác nhau chỉ loại trùng tuyệt đối, chưa loại được các bản thu gần trùng.

3. Quy mô, thời lượng và độ phù hợp của tệp

Bảng 5: Số lượng và thời lượng đo trực tiếp trên phiên bản 655 tệp. Đơn vị thời lượng: giây.

Nhãn nhạc cụ	Số tệp	Ngắn nhất	Trung vị	Dài nhất
agogo	16	0,464	0,673	0,999
claves	13	0,163	0,209	0,511
conga	18	0,139	0,476	0,906
cowbell	43	0,110	0,232	0,720
cymbal	33	0,371	0,766	0,999
hi-hat	93	0,108	5,647	19,249
kick	151	0,109	0,480	20,615
marimba	36	0,712	2,000	2,000
snare	141	0,114	0,464	17,104
tambourine	12	0,154	0,395	0,418
tom	76	0,107	0,720	0,999
vibraphone	12	2,000	2,000	2,000
xylophone	11	0,283	0,510	0,958
Tổng	**655**	**0,107**	**0,534**	**20,615**

Tổng thời lượng là **1.583,158 giây**, khoảng 26 phút 23 giây; dung lượng âm thanh là 50.689.868 byte, khoảng 48,34 MiB. Có 514 tệp dài không quá một giây. Lớp ít nhất là xylophone với 11 tệp, lớp nhiều nhất là kick với 151 tệp, nên dữ liệu không cân bằng giữa các lớp.

3.1 Vì sao không ép mọi tệp về cùng độ dài

Một đoạn âm thanh phù hợp cần giữ được những phần có ích cho việc phân biệt: thời điểm khởi âm, phần cộng hưởng và diễn biến suy giảm hoặc lặp lại. Tiếng claves hay cowbell vốn rất ngắn; kéo dài bằng im lặng không bổ sung thông tin. Ngược lại, cắt một chuỗi hi-hat hay một tiếng ngân theo cùng một ngưỡng ngắn có thể làm mất đặc điểm thời gian.

Vì vậy, bộ dữ liệu giữ độ dài khác nhau và chuyển mỗi tệp thành vector có số chiều cố định bằng thống kê theo khung (Mục 6). Ngưỡng 0,1 s chỉ là bước sàng lọc kỹ thuật. Độ phù hợp thực tế còn phụ thuộc tốc độ

suy giảm, việc tệp có bị cắt cụt ở đầu hoặc cuối không và kỹ thuật biểu diễn, nên không thể đánh giá chỉ bằng tổng thời lượng.

3.2 Ảnh hưởng của dạng bản ghi

Có 92 tệp dài hơn 2 s, đều là chuỗi nhiều lần gõ từ IDMT: 53 hi-hat, 31 kick và 8 snare. Riêng hi-hat chiếm khoảng 700 s, gần một nửa tổng thời lượng của bộ dữ liệu. Vì vậy, tệp hi-hat dài hơn tệp claves không có nghĩa một lần đánh hi-hat ngân lâu hơn. Thời lượng tệp và khoảng chứa 90% năng lượng phản ánh cả cách cắt, số lần đánh, khoảng nghỉ lẫn bao âm. Ảnh hưởng của dạng bản ghi lên khoảng cách đặc trưng được đo ở Mục 11.

Các đoạn Iowa được trích với độ dài tối đa 2 s; cả 12 tệp vibraphone và 33/36 tệp marimba chạm mức này, nên đuôi ngân dài của hai nhạc cụ bị cắt bớt. Trên các tệp đại diện ở Hình 1, phần khởi âm và phần đầu của quá trình suy giảm vẫn được giữ, đủ để thấy các vạch cộng hưởng đặc trưng.

4. Đặc điểm giống và khác nhau của tiếng nhạc cụ

4.1 Những đặc điểm chung

Tiếng bộ gõ thường bắt đầu bằng một kích thích nhanh, sau đó cộng hưởng và suy giảm; một tệp có thể chứa nhiều lần kích thích. Phổ của âm gồm các vạch hoặc vùng tập trung năng lượng xen với thành phần trải rộng giống nhiễu, với tỷ lệ khác nhau tùy nhạc cụ. Vật liệu, cấu tạo, vị trí đánh, lực đánh và cách hãm tiếng tạo nên khác biệt về độ trầm, độ sáng, độ rè và thời gian tồn tại của âm.

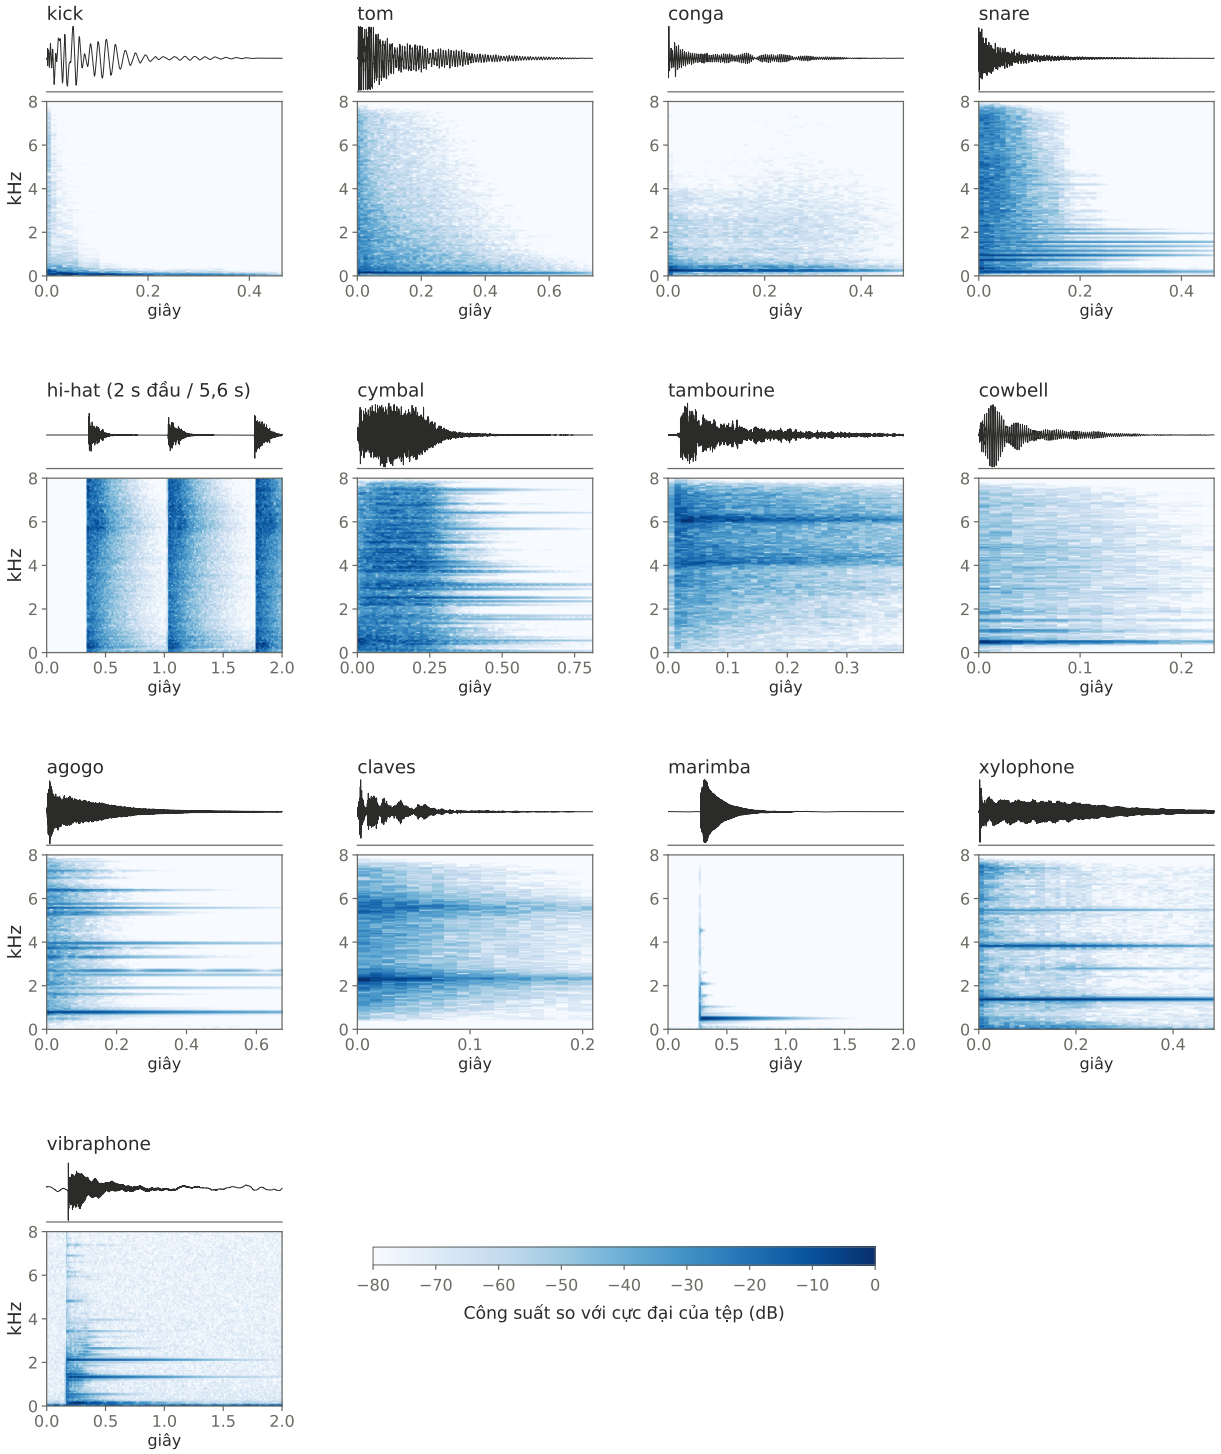
Hai tệp cùng nhạc cụ không nhất thiết giống hệt nhau, và hai nhạc cụ khác nhau có thể có chung một số tính chất. Kick, conga và tom đều giàu năng lượng thấp; hi-hat và tambourine đều có nhiều năng lượng cao. Do đó, việc nhận diện cần một tập thuộc tính bổ sung cho nhau thay vì một ngưỡng đơn lẻ.

4.2 Quan sát trên phổ đồ

Hình 1 cho thấy dạng sóng và phổ đồ của một tệp đại diện cho mỗi nhóm. Tệp đại diện của mỗi nhóm là tệp gần trung vị của nhóm nhất khi xét đồng thời thời lượng và trọng tâm phổ (so sánh theo thang logarit); phổ đồ dùng cùng thiết lập khung với bộ đặc trưng (25 ms, bước 10 ms, FFT 512 điểm).

Các điểm giống và khác nhau nhìn thấy được trên Hình 1:

- **Trống màng rung trầm (kick, tom, conga):** năng lượng dồn vào vài vạch thấp; phổ trung bình của tệp đại diện có đỉnh khoảng 52 Hz (kick), 122 Hz (tom), 232 và 393 Hz (conga). Ngoài ra chỉ có một vệt rộng dải rất ngắn lúc khởi âm. Tom ngân dài hơn kick và conga.
- **Snare:** giống ba trống trên ở các vạch thân trống dưới 1,5 kHz, nhưng khác ở vùng nhiễu rộng tới 8 kHz trong khoảng 0,2 s đầu do dây lò xo.
- **Hi-hat và cymbal:** cùng có phổ dày đặc, trải gần hết 0–8 kHz. Cymbal ngân lâu với nhiều vạch xen nhau; mỗi lần đánh hi-hat là một vệt dọc ngắn, lặp lại theo nhịp.
- **Tambourine:** cũng sáng như hi-hat nhưng năng lượng dồn vào hai dải hẹp quanh 4,1–4,8 kHz và 6,1–6,3 kHz, kéo dài suốt tệp, thay vì trải đều như nhiễu.
- **Cowbell và agogo:** đều là chuông kim loại với vài vạch cộng hưởng rời rạc. Vạch của cowbell nằm thấp (khoảng 0,48 và 1,0 kHz) và tắt nhanh; agogo có các vạch cao hơn (khoảng 0,8; 2,7; 4,0 và 5,6 kHz) và ngân lâu hơn.
- **Claves:** rất ngắn (khoảng 0,2 s), năng lượng tập trung ở hai cụm quanh 2,1–2,5 kHz và 5,5–5,8 kHz.
- **Marimba, xylophone, vibraphone:** cùng có các vạch nằm ngang rõ, đặc trưng của thanh gõ lên dây theo nốt. Marimba gần như chỉ còn một vạch chính (khoảng 0,53 kHz, gần nốt C5), xylophone có các vạch ở 1,4 và 3,8 kHz, còn vibraphone có các vạch dưới 2,2 kHz ngân suốt 2 s.



Hình 1: Dạng sóng (trên) và phổ đồ 0–8 kHz (dưới) của tệp đại diện mỗi nhóm, xếp theo họ nhạc cụ ở Bảng 2. Tệp hi-hat lấy từ IDMT, marimba và vibraphone lấy từ Iowa, các tệp còn lại lấy từ Freesound. Mỗi ô có trục thời gian riêng theo độ dài tệp, tối đa 2 s; tệp hi-hat là chuỗi nhiều lần đánh nên chỉ vẽ 2 s đầu. Màu đậm là công suất gần cực đại của tệp. Năng lượng của kick, tom, conga tập trung dưới 0,5 kHz nên chỉ chiếm dải hẹp ở đáy phổ đồ.

4.3 Mô tả 13 nhóm và các dấu hiệu so sánh

Bảng 6 tổng hợp đặc điểm của từng nhóm, dựa trên cấu tạo nhạc cụ, phổ đồ ở Hình 1 và số đo ở Mục 5. Đặc điểm của từng tệp có thể thay đổi theo cách chơi và cách xử lý bản thu.

Bảng 6: Đặc điểm của 13 nhóm nhạc cụ và nhóm dễ nhầm lẫn với chúng.

Nhạc cụ	Đặc điểm và điểm so sánh đáng chú ý
Kick	Thân tiếng rất trầm, xung năng lượng mạnh và tắt nhanh. Gần tom và conga ở năng lượng thấp; khác ở vị trí vạch trầm và diễn biến năng lượng.
Tom	Cộng hưởng mặt trống, có thân tiếng và đuôi suy giảm dài hơn kick. Gần conga nhất trong bộ dữ liệu.
Conga	Trống tay; tiếng thay đổi theo cách đánh mở, hãm hoặc vỗ. Phần trầm gần tom, phần đầu tiếng thay đổi mạnh theo kỹ thuật.
Snare	Thân tiếng trống kết hợp phần rè của dây lò xo, nên phổ phân tán hơn các trống trầm và gần cymbal ở thành phần nhiễu.
Hi-hat	Tiếng kim loại sáng, phổ gần giống nhiễu; đóng hay mở tạo độ ngân khác nhau. Gần tambourine về độ sáng, gần cymbal và snare về độ phân tán.
Cymbal	Nhiều thành phần kim loại, phổ trải rộng, đuôi ngân dài. Có chung tính nhiễu với hi-hat và snare.
Tambourine	Các miếng kim loại nhỏ tạo tiếng leng keng ở dải cao, tập trung vào vài dải hẹp. Trọng tâm phổ cao nhất bộ dữ liệu.
Cowbell	Chuông kim loại với vài vạch cộng hưởng thấp, tắt nhanh. Cùng kiểu vạch rời rạc với agogo nhưng vạch nằm thấp hơn.
Agogo	Chuông gõ với các vạch cộng hưởng rời rạc ở dải trung và cao; cỡ chuông và lực đánh làm dịch vạch. Phân biệt với cowbell nhờ vị trí vạch.
Claves	Va chạm hai thanh gỗ, rất ngắn và sắc, năng lượng tập trung ở vài kHz. Khởi âm rõ như nhiều nhạc cụ khác nhưng đuôi tiếng ngắn nhất.
Marimba	Thanh gỗ có cao độ, có ống cộng hưởng; năng lượng dồn vào vạch cơ bản, vạch cao tắt nhanh. Cao độ nốt làm dịch toàn bộ phổ.
Vibraphone	Thanh kim loại có cao độ, ngân dài nếu không hãm tiếng. Gần marimba về độ tập trung phổ.
Xylophone	Thanh gỗ có cao độ, âm sáng và khởi âm rõ. Trong bộ dữ liệu có trọng tâm phổ cao hơn hẳn marimba và vibraphone.

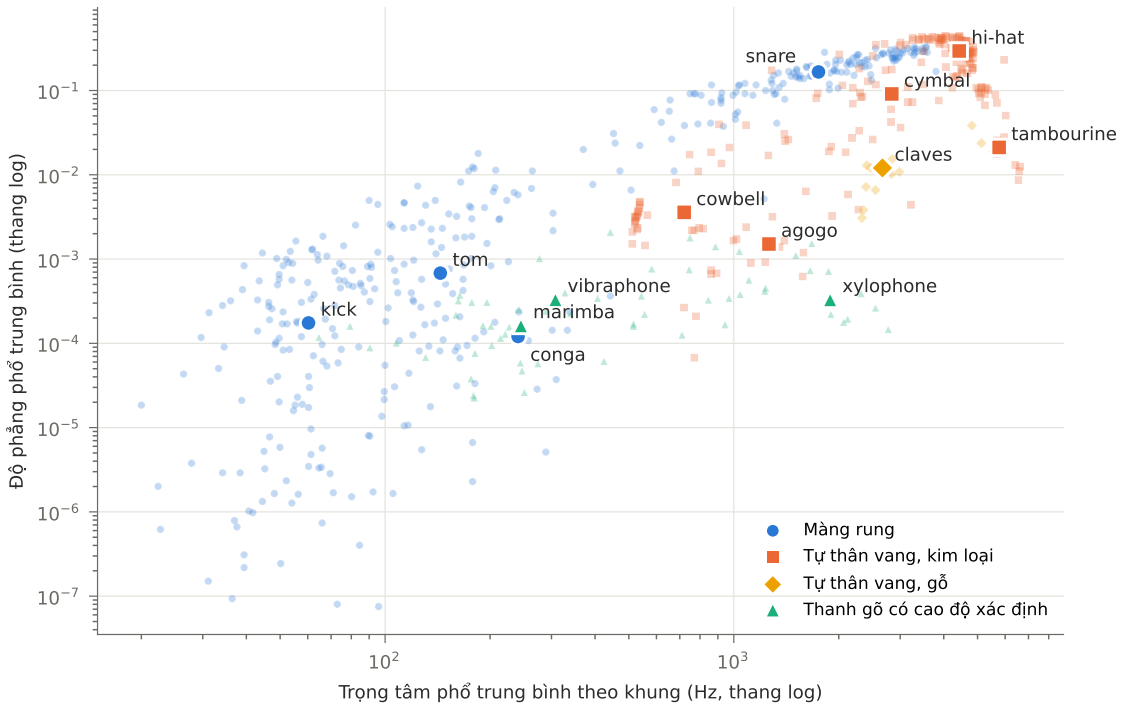
5. So sánh định lượng tiếng nhạc cụ

5.1 Cách đọc số liệu

Mỗi tệp được chia khung; các đại lượng được tính trên khung có tín hiệu rồi lấy trung bình trong tệp. Bảng 7 cho **trung vị của các giá trị trung bình theo tệp trong từng lớp**. Đây là giá trị tiêu biểu của lớp, không mô tả hết biến thiên bên trong lớp. Công thức và cách chọn khung được nêu ở Mục 6–8.

Bảng 7: Các đại lượng phổ đo trên bộ dữ liệu (trung vị theo lớp). C: trọng tâm phổ; F: độ phẳng phổ; H: entropy phổ; L: tỷ lệ năng lượng dưới 500 Hz; Φ: thông lượng phổ.

Nhãn	C (Hz)	F	H	L (%)	Φ
agogo	1.261,3	0,0015	0,272	$< 0,01$	0,045
claves	2.668,7	0,0121	0,458	$< 0,01$	0,363
conga	240,6	0,0001	0,256	99,61	0,117
cowbell	720,6	0,0036	0,252	42,04	0,141
cymbal	2.838,4	0,0910	0,710	3,38	0,338
hi-hat	4.429,7	0,2945	0,839	9,23	0,403
kick	60,3	0,0002	0,229	99,84	0,188
marimba	245,2	0,0002	0,219	78,91	0,059
snare	1.749,6	0,1661	0,696	29,89	0,353
tambourine	5.766,8	0,0211	0,584	0,01	0,397
tom	144,0	0,0007	0,234	99,20	0,088
vibraphone	307,9	0,0003	0,198	76,85	0,053
xylophone	1.889,3	0,0003	0,254	5,85	0,070



Hình 2: Trọng tâm phổ và độ phẳng phổ của 655 tệp (điểm nhạt) và trung vị từng lớp (điểm đậm có nhãn), tô màu và phân biệt hình dạng điểm theo bốn họ nhạc cụ ở Bảng 2. Cả hai trục dùng thang logarit.

5.2 Những tương đồng và khác biệt quan sát được

Nhóm trống trầm: kick, tom và conga có tỷ lệ năng lượng dưới 500 Hz lần lượt 99,84%, 99,20% và 99,61%, nên tương đồng rõ theo dấu hiệu năng lượng thấp. Trọng tâm phổ lần lượt khoảng 60,3; 144,0 và 240,6 Hz cho thấy vị trí năng lượng trong dải trầm vẫn khác nhau. Trên Hình 2, ba lớp nằm ở góc trái dưới nhưng các điểm của từng tệp chồng lấn nhau đáng kể.

Nhóm phổ phân tán: hi-hat có entropy 0,839, cymbal 0,710 và snare 0,696, cao hơn hẳn nhóm trống trầm.

Hi-hat và tambourine cùng sáng (trọng tâm khoảng 4.429,7 và 5.766,8 Hz), nhưng độ phẳng lần lượt là 0,2945 và 0,0211. Như vậy, nhiều năng lượng ở dải cao không đồng nghĩa với phổ phẳng; phổ đồ của tambourine ở Hình 1 cũng cho thấy năng lượng dồn vào vài dải hẹp. Kết hợp trọng tâm với độ phẳng giúp tách hai trường hợp này.

Nhóm thanh gõ có cao độ: marimba và vibraphone đều có độ phẳng rất thấp và entropy thấp nhất bộ dữ liệu (0,219 và 0,198), phù hợp với phổ gồm vài vạch rõ. Đây là điểm giống nhau cần được phản ánh khi tìm âm tương tự. Xylophone có trọng tâm 1.889,3 Hz, khác rõ marimba (245,2 Hz) và vibraphone (307,9 Hz). Chênh lệch này có thể một phần do khác nguồn thu (xylophone lấy từ Freesound, còn marimba và vibraphone đều lấy từ Iowa), một phần do xylophone có âm vực cao và âm sắc sáng hơn; dữ liệu hiện tại chưa tách được hai nguyên nhân này.

Agogo và cowbell: cùng có phổ tập trung, nhưng tỷ lệ năng lượng dưới 500 Hz rất khác nhau: agogo khoảng 0,002%, cowbell 42,04%. Điều này khớp với vị trí vạch cộng hưởng trên phổ đồ, nên kết hợp tỷ lệ năng lượng thấp với hình dạng bao phổ có ích hơn việc gộp cả hai là "tiếng chuông kim loại".

Phần II. Yêu cầu 2: Các bộ đặc trưng nhận diện âm thanh

6. Quy trình biểu diễn âm thanh

6.1 Từ tệp âm thanh đến vector đặc trưng

Trong báo cáo, một *bộ đặc trưng* là một vector có số chiều cố định, mỗi chiều là một *thuộc tính* tính từ nội dung âm thanh. Quy trình chung là: **đọc WAV → bỏ thành phần một chiều (DC) và chuẩn hóa đỉnh → xác định vùng có tín hiệu → chia khung → tính các đại lượng thời gian, phổ và MFCC → tổng hợp theo tệp → chuẩn hóa thuộc tính → tính khoảng cách**. Nhờ đó, các tệp dài ngắn khác nhau được đưa về cùng một dạng biểu diễn, có thể lưu trong cơ sở dữ liệu và so sánh theo nội dung.

Gọi $x[n]$ là mẫu tín hiệu và N là số mẫu. Tín hiệu dùng khi tính đặc trưng là

$$y[n] = \frac{x[n] - \bar{x}}{\max_n |x[n] - \bar{x}|}, \qquad \bar{x} = \frac{1}{N} \sum_{n=0}^{N-1} x[n].$$

Phép trừ trung bình loại thành phần DC; phép chia cho đỉnh loại ảnh hưởng của hệ số khuếch đại (gain) toàn tệp. Biên độ thu tuyệt đối không được dùng làm dấu hiệu nhạc cụ, vì khoảng cách micro và mức khuếch đại tạo ra khác biệt không liên quan đến âm sắc.

Bảng 8: Thiết lập xử lý tín hiệu dùng cho cả ba bộ đặc trưng.

Thành phần	Thiết lập đã dùng
Tín hiệu đầu vào	Mono, $f_s = 16.000$ Hz; tính toán bằng số thực 64-bit.
Bao RMS cho thời gian	Các khối 160 mẫu (10 ms), không chồng nhau; khối cuối có thể ngắn hơn. Khối có tín hiệu khi RMS $> 0,01$ sau chuẩn hóa đỉnh.
Khung phân tích phổ	400 mẫu (25 ms), bước 160 mẫu (10 ms); thêm số 0 ở cuối để đủ khung.
Khung phổ hợp lệ	RMS trước khi nhân cửa sổ $> 0,01$; cửa sổ Hann dạng tuần hoàn.
Biến đổi phổ	FFT 512 điểm; 257 bin từ 0 đến 8 kHz, bước bin 31,25 Hz.
Tổng hợp	Trung bình và độ lệch chuẩn tổng thể (chia cho số khung hợp lệ) trên các khung hợp lệ; thông lượng phổ và delta có điều kiện hợp lệ riêng.

Với khung t, gọi $P_t[k] = |\text{FFT}(y_t w)[k]|^2$ và $f_k = 16000k/512$, $k = 0, \ldots, 256$. Phân bố công suất chuẩn hóa là

$$q_t[k] = \frac{P_t[k]}{\sum_{j=0}^{256} P_t[j]},$$

với mẫu số được chặn dưới ở 10^{-30} trong chương trình. Các công thức phổ dùng **công suất** thay vì biên độ, trừ thông lượng phổ có thêm bước lấy căn. FFT được đệm từ 400 lên 512 điểm để có lưới tần số thuận tiện; việc đệm không làm tăng độ phân giải tần số thực của khung 25 ms.

6.2 Ba bộ đặc trưng được xây dựng

A (21 chiều): 5 thuộc tính thời gian và 16 thuộc tính phổ, dễ diễn giải trực tiếp. **B (39 chiều):** các thống kê của MFCC, mô tả hình dạng bao phổ và mức biến thiên của nó. **C (60 chiều):** ghép A và B sau chuẩn hóa, cân bằng trọng số giữa hai khối. Tất cả thuộc tính đều tính từ nội dung âm thanh; nhãn chỉ dùng để phân tích kết quả.

6.3 Đối chiếu với các nhóm đặc trưng âm thanh thông dụng

Các đặc trưng âm thanh thường được chia thành nhóm miền thời gian và nhóm miền tần số [6]. Bộ A và B bao phủ các nhóm này như sau:

- **Miền thời gian:** tỷ lệ đổi dấu (ZCR) là Z ở Mục 8; ZCR tính trực tiếp trên dạng sóng nhưng theo cùng khung 25 ms với các đại lượng phổ, nên trong bộ A được xếp vào khối 16 thuộc tính theo khung (gọi tắt là khối phổ); tỷ lệ có tín hiệu a_4 tương ứng với $1 -$ tỷ lệ im lặng, tính trong khoảng từ đầu đến cuối vùng có tín hiệu; năng lượng được mô tả qua hệ số đỉnh a_3 và khoảng chứa 90% năng lượng a_2. Năng lượng trung bình tuyệt đối không được dùng vì phụ thuộc mức khuếch đại.
- **Miền tần số:** độ rộng băng tần (bandwidth) là W; phân bố năng lượng theo tần số được mô tả bởi C, R, L và các hệ số MFCC; độ phẳng và entropy phổ đo mức tập trung hay phân tán của phổ.
- **Cao độ và độ hài hòa (pitch, harmonicity):** không đưa vào ba bộ hiện tại. 10/13 nhóm không có cao độ xác định, và phổ của chuông, thanh gõ là phổ không hài hòa, nên ước lượng tần số cơ bản thường không ổn định. Với ba nhạc cụ có cao độ, tần số cơ bản thay đổi theo nốt được chơi, nên dễ tách các nốt hơn là tách các nhạc cụ. Mức "có vạch rõ hay giống nhiễu" của phổ đã được phản ánh một phần qua độ phẳng và entropy. Bổ sung độ hài hòa là một hướng mở rộng (Mục 13).

7. Bộ A: năm thuộc tính thời gian

Đặt $\mathcal{A}$ là tập mẫu thuộc các khối 10 ms có tín hiệu; n_0, n_1 là mẫu có tín hiệu đầu tiên và cuối cùng. $T_a = |\mathcal{A}|/f_s$ là tổng thời gian có tín hiệu, $T_s = (n_1 - n_0 + 1)/f_s$ là độ dài từ đầu đến cuối vùng có tín hiệu, kể cả các khoảng nghỉ ở giữa.

7.1 Thời gian có tín hiệu và khoảng chứa 90% năng lượng

$$a_1 = \ln(1 + T_a), \qquad a_2 = \ln(1 + D_{90}), \qquad D_{90} = \frac{n_{95} - n_{05}}{f_s},$$

trong đó thời gian tính bằng giây và n_p là vị trí đầu tiên mà năng lượng tích lũy đạt $p\%$ tổng năng lượng $\sum_n y[n]^2$. Logarit tự nhiên nén khoảng giá trị, tránh để một chuỗi dài lấn át các tiếng gõ ngắn.

Giá trị thông tin: T_a cho biết lượng tín hiệu thực sự xuất hiện; D_{90} cho biết năng lượng tập trung trong một khoảng ngắn hay trải trên khoảng dài. Hai tệp có cùng kiểu kích thích và suy giảm sẽ gần nhau theo hai thuộc tính này; khác biệt về độ ngân, hãm tiếng hay số lần gõ sẽ đẩy chúng ra xa. Với tệp chứa nhiều lần gõ, D_{90} đo cả chuỗi chứ không đo thời gian suy giảm của một lần gõ.

7.2 Hệ số đỉnh trên vùng có tín hiệu

$$a_3 = 20 \log_{10} \left(\frac{1}{\sqrt{|\mathcal{A}|^{-1} \sum_{n \in \mathcal{A}} y[n]^2}} \right) \quad \text{(dB)}.$$

Do đỉnh toàn tệp đã được chuẩn hóa bằng 1, hệ số đỉnh (crest factor) lớn nghĩa là đỉnh nổi bật so với mức RMS của vùng có tín hiệu, còn hệ số đỉnh nhỏ nghĩa là năng lượng được duy trì đều hơn. Thuộc tính này giúp phân biệt xung gõ nhọn với âm kéo dài, nhưng cũng chịu ảnh hưởng của nén dải động (dynamic range compression) khi xử lý bản thu, cách chơi và số lần gõ trong tệp.

7.3 Tỷ lệ có tín hiệu và vị trí đỉnh bao RMS

$$a_4 = \frac{T_a}{T_s}, \qquad a_5 = \min\left(\max\left(\frac{160 b_{\max} - n_0}{\max(n_1 - n_0, 1)}, 0 \right), 1 \right),$$

trong đó $b_{\max}$ là chỉ số khối 10 ms có RMS lớn nhất. a_4 gần 1 khi tín hiệu liên tục, nhỏ hơn khi có khoảng nghỉ. a_5 gần 0 khi khối mạnh nhất nằm ở đầu vùng có tín hiệu, lớn hơn khi cực đại đến muộn.

Giá trị thông tin: tỷ lệ có tín hiệu mô tả tính liên tục; vị trí đỉnh mô tả năng lượng phân bố ra sao theo trục thời gian. Hai thuộc tính này phản ánh cấu trúc bản ghi và một phần bao âm. Với chuỗi nhiều lần gõ, cực đại có thể rơi vào bất kỳ lần gõ nào, nên a_5 không đo thời gian khởi âm của từng nốt.

Nhóm thời gian trả lời câu hỏi "năng lượng xuất hiện như thế nào theo thời gian"; nhóm phổ ở mục tiếp theo trả lời "năng lượng nằm ở những vùng tần số nào". Hai nhóm bổ sung cho nhau.

8. Bộ A: tám đại lượng phổ và cách tổng hợp

8.1 Vị trí và độ trải rộng năng lượng

Trọng tâm phổ (spectral centroid) và **độ rộng phổ** (bandwidth) được tính theo

$$C_t = \sum_k f_k q_t[k], \qquad W_t = \sqrt{\sum_k (f_k - C_t)^2 q_t[k]}.$$

Cả hai có đơn vị Hz. C_t là vị trí trung bình của năng lượng, thường gắn với cảm nhận độ sáng; W_t là mức trải rộng quanh trọng tâm. Hai âm có cùng trọng tâm vẫn có thể có độ rộng khác nhau. C_t không phải tần số cơ bản hay cao độ của âm.

Tần số cắt 85% (rolloff) là $R_t = f_{k^*}$ với $k^* = \min\{k : \sum_{j=0}^{k} q_t[j] \geq 0,85\}$, tức tần số mà phần lớn năng lượng đã nằm bên dưới. Đại lượng này thường tương quan với trọng tâm nhưng mang nghĩa khác: một bên là phân vị năng lượng, một bên là trung bình có trọng số.

Tỷ lệ năng lượng thấp $L_t = \sum_{f_k < 500\,\text{Hz}} q_t[k]$ nằm trong $[0, 1]$, với ngưỡng là *nhỏ hơn* 500 Hz. Giá trị cao gắn với các tiếng giàu âm trầm; giá trị thấp giúp tách chúng khỏi nhiều tiếng kim loại sáng. Vì là tỷ lệ, đại lượng này không phụ thuộc mức âm lượng.

8.2 Độ tập trung và tính nhiễu của phổ

Độ phẳng phổ (spectral flatness):

$$F_t = \frac{\exp\left(\frac{1}{K}\sum_k \ln \widetilde{P}_t[k]\right)}{\frac{1}{K}\sum_k \widetilde{P}_t[k]}, \qquad K = 257,$$

trong đó $\widetilde{P}_t[k] = \max(P_t[k], 10^{-12}\max(\max_j P_t[j], 10^{-30}))$. Giá trị gần 0 cho biết phổ có các đỉnh nổi bật; giá trị gần 1 cho biết công suất phân bố đều giữa các bin, giống nhiễu. Độ phẳng giúp phân biệt phổ tập trung với phổ giống nhiễu, nhưng không trực tiếp cho biết vật liệu của nhạc cụ.

Entropy phổ chuẩn hóa: $H_t = -\sum_k q_t[k] \ln q_t[k] / \ln K$, với quy ước $0 \ln 0 = 0$. Giá trị cao nghĩa là năng lượng phân tán trên nhiều bin. Entropy và độ phẳng cùng đo mức phân tán nhưng nhạy khác nhau với các bin năng lượng nhỏ, nên cả hai được giữ lại.

8.3 Mức dao động và thay đổi giữa các khung

Tỷ lệ đổi dấu (ZCR): $Z_t = \frac{1}{399}\sum_{n=1}^{399} \mathbf{1}\big[(y_t[n] < 0) \neq (y_t[n-1] < 0)\big]$, tính trên khung trước khi nhân cửa sổ. Đổi dấu nhiều thường đi cùng thành phần tần số cao hoặc nhiễu. Với tiếng bộ gõ phức tạp, ZCR không phải ước lượng cao độ đáng tin cậy.

Thông lượng phổ dương (spectral flux): $\Phi_t = \sqrt{\sum_k [\max(\sqrt{q_t[k]} - \sqrt{q_{t-1}[k]}, 0)]^2}$, chỉ tính khi hai khung liền nhau đều hợp lệ, không nối qua vùng im lặng. Thông lượng phổ đo mức thay đổi hình dạng phổ khi âm khởi phát hoặc biến đổi, bổ sung cho các đại lượng tính trên từng khung riêng lẻ.

8.4 Từ tám chuỗi giá trị thành 16 thuộc tính

Với mỗi chuỗi v_t trong tám đại lượng trên, lấy trung bình μ_v và độ lệch chuẩn $\sigma_v = \sqrt{M^{-1}\sum_t (v_t - \mu_v)^2}$ trên M khung hợp lệ. Trung bình mô tả trạng thái điển hình; độ lệch chuẩn mô tả mức biến thiên trong tệp. 16 giá trị này cùng 5 thuộc tính thời gian tạo thành **bộ A có 21 chiều**. Trong báo cáo, 16 thuộc tính này được gọi chung là khối phổ của bộ A; riêng ZCR tính trên dạng sóng của từng khung.

9. Bộ B: MFCC và thông tin về bao phổ

9.1 Từ phổ công suất đến hệ số cepstrum

Các đại lượng trong A là những tóm tắt riêng lẻ của phổ. MFCC (Mel-frequency cepstral coefficients) [5] bổ sung một biểu diễn gọn của **hình dạng năng lượng theo các dải tần Mel**, giúp phân biệt hai âm có trọng tâm gần nhau nhưng phân bố năng lượng giữa các dải khác nhau.

Chương trình dùng 40 bộ lọc tam giác, các điểm biên cách đều theo thang Mel HTK từ 20 Hz đến 8 kHz:

$$m(f) = 2595 \log_{10}(1 + f/700).$$

42 điểm biên tạo 40 tam giác; trọng số của mỗi bộ lọc được chuẩn hóa để tổng trên lưới FFT bằng 1. Năng lượng và log năng lượng của dải b là

$$E_t[b] = \sum_k H_b[k] P_t[k], \qquad \ell_t[b] = \ln \max(E_t[b], 10^{-10}), \quad b = 0, \ldots, 39.$$

Áp dụng DCT loại II chuẩn trực giao và giữ các hệ số $r = 1, \ldots, 13$:

$$c_t[r] = \sqrt{\frac{2}{40}} \sum_{b=0}^{39} \ell_t[b] \cos\left[\frac{\pi r}{40}\left(b + \frac{1}{2}\right)\right].$$

Hệ số c_0 không được giữ. Phép DCT được tính bằng thư viện SciPy [7] theo đúng công thức trên. Các quy ước về thang Mel, logarit, chuẩn hóa bộ lọc và chọn hệ số được nêu rõ vì thư viện hoặc thiết lập khác sẽ cho giá trị khác.

9.2 Ba nhóm thống kê, tổng cộng 39 chiều

Với từng hệ số từ 1 đến 13, lấy **trung bình** và **độ lệch chuẩn** trên các khung hợp lệ, được 26 giá trị. Tiếp theo tính sai phân theo thời gian (delta):

$$\Delta c_t[r] = \frac{c_{t+1}[r] - c_{t-1}[r] + 2(c_{t+2}[r] - c_{t-2}[r])}{10}.$$

Hai đầu chuỗi được mở rộng bằng cách lặp giá trị đầu và cuối. Một giá trị delta chỉ được dùng khi cả năm vị trí trong cửa sổ đều hợp lệ. Lấy **độ lệch chuẩn của delta** cho 13 hệ số, được thêm 13 giá trị. Bộ B có $13 + 13 + 13 = 39$ chiều.

9.3 Giá trị thông tin và giới hạn

Trung bình MFCC mô tả dạng bao phổ điển hình. Vì đã bỏ c_0, hai tệp cùng nhạc cụ có thể gần nhau dù âm lượng gốc khác nhau. **Độ lệch chuẩn MFCC** cho biết bao phổ ổn định hay thay đổi trong tệp. **Độ lệch chuẩn delta** bổ sung mức biến đổi cục bộ theo thời gian, hữu ích cho các đoạn khởi âm nhanh, cộng hưởng và chuyển tiếp.

MFCC phân biệt được những trường hợp cùng giàu âm trầm hoặc cùng có phổ tập trung nhưng phân bố khác nhau giữa các dải. Đổi lại, từng hệ số không có ý nghĩa vật lý đơn giản như “Hz” hay “giây”. MFCC cũng chịu ảnh hưởng của cách thu, bộ cân bằng tần số (EQ), cao độ nốt được chơi và nguồn dữ liệu; việc lấy trung bình và độ lệch chuẩn làm mất thứ tự chính xác của các sự kiện.

10. Bộ C và phép đo tương đồng

10.1 Chuẩn hóa để so sánh các thuộc tính khác đơn vị

Không thể cộng trực tiếp chênh lệch tính bằng Hz, giây và các tỷ lệ trong $[0, 1]$. Với thuộc tính j, chuẩn hóa theo

$$z_j(x) = \frac{x_j - \mu_j}{s_j},$$

trong đó μ_j, s_j là trung bình và độ lệch chuẩn trên 655 tệp; nếu $s_j < 10^{-12}$ thì thay bằng 1 để tránh chia cho 0. Các tham số được lưu lại để dùng khi tính vector cho âm thanh truy vấn.

Đặt $z_A \in \mathbb{R}^{21}$ và $z_B \in \mathbb{R}^{39}$. Các vector dùng để tính khoảng cách là

$$u_A = \frac{z_A}{\sqrt{21}}, \qquad u_B = \frac{z_B}{\sqrt{39}}, \qquad u_C = \left[\frac{z_A}{\sqrt{42}}, \frac{z_B}{\sqrt{78}}\right].$$

Chia cho căn số chiều giúp khoảng cách của hai bộ có thang đo tương đương. Bộ C có **60 chiều** và mỗi khối đóng góp một nửa vào bình phương khoảng cách, thay vì để B lấn át chỉ vì có nhiều chiều hơn.

10.2 Khoảng cách biểu diễn cả giống và khác nhau

Với hai tệp x, y, dùng khoảng cách Euclid

$$d_S(x, y) = \|u_S(x) - u_S(y)\|_2, \qquad S \in \{A, B, C\}.$$

Khoảng cách nhỏ nghĩa là hai âm tương đồng theo bộ thuộc tính đã chọn; khoảng cách lớn nghĩa là chúng khác biệt. Từ định nghĩa của bộ C suy ra

$$\boxed{d_C^2(x, y) = \tfrac{1}{2} d_A^2(x, y) + \tfrac{1}{2} d_B^2(x, y).}$$

Đẳng thức này đúng cho từng cặp tệp, không áp dụng cho các khoảng cách trung bình trong bảng kết quả. Khi cần hiển thị độ tương đồng trong $(0, 1]$, có thể dùng $s = 1/(1 + d)$; đây chỉ là phép biến đổi đơn điệu, không phải xác suất hai tệp cùng nhạc cụ.

10.3 Sử dụng trong cơ sở dữ liệu đa phương tiện

Mỗi đối tượng lưu mã tệp, nhãn, đường dẫn, metadata nguồn và vector đặc trưng. Khi có âm thanh truy vấn, hệ thống áp dụng cùng quy trình xử lý và cùng bộ tham số chuẩn hóa, tính khoảng cách đến các vector trong kho rồi sắp xếp tăng dần để trả về các âm tương tự nhất. Nếu truy vấn là một tệp đã có trong kho thì loại chính tệp đó khỏi kết quả.

Cách biểu diễn này cho phép tìm theo nội dung âm thanh thay vì theo tên. Bộ A dễ giải thích vì chỉ ra được hai âm giống nhau ở năng lượng trầm, độ sáng hay độ phân tán; bộ B bổ sung hình dạng bao phổ; bộ C dùng đồng thời cả hai loại thông tin.

11. Giá trị thông tin thể hiện qua số liệu

11.1 So sánh khoảng cách trong lớp và giữa các lớp

Gọi $\mathcal{D}_c$ là tập tệp có nhãn c, $n_c = |\mathcal{D}_c|$ và $G = 13$. Khoảng cách trong lớp là trung bình trên mọi cặp tệp trong lớp, sau đó lấy trung bình đều giữa các lớp:

$$D_{\text{trong}} = \frac{1}{G} \sum_c \frac{2}{n_c(n_c - 1)} \sum_{i<j;\ i,j \in \mathcal{D}_c} d(i, j).$$

Khoảng cách giữa lớp là trung bình mọi cặp tệp của từng cặp lớp, sau đó lấy trung bình đều trên $\binom{13}{2} = 78$ cặp lớp:

$$D_{\text{ngoài}} = \frac{1}{\binom{G}{2}} \sum_{c<d} \frac{1}{n_c n_d} \sum_{i \in \mathcal{D}_c} \sum_{j \in \mathcal{D}_d} d(i,j).$$

Tỷ số $Q = D_{\text{ngoài}}/D_{\text{trong}}$ biểu thị mức tách lớp trung bình; Q càng lớn thì các lớp càng tách nhau. Lấy trung bình đều theo lớp giúp các lớp nhiều tệp như kick, snare không lấn át các lớp ít tệp. Cả ba bộ đều có khoảng

Bảng 9: Khoảng cách trong lớp, giữa lớp và tỷ số Q trên toàn bộ 655 tệp.

Bộ	Số chiều	D_{trong}	$D_{\text{ngoài}}$	Q
A	21	0,731	1,269	1,735
B	39	1,168	1,607	1,376
C	60	1,010	1,487	1,473

cách giữa lớp lớn hơn trong lớp. **A có tỷ số cao nhất (1,735)**; C đạt 1,473, thấp hơn A dù nhiều chiều hơn. Như vậy, thêm MFCC không tự động làm các lớp tách nhau rõ hơn; việc chọn bộ tốt nhất cần dựa thêm vào từng cặp lớp và đánh giá trên dữ liệu mới.

11.2 Kiểm tra ảnh hưởng của chuỗi dài lên tỷ số Q

Để kiểm tra các chuỗi IDMT dài có làm lệch kết quả hay không, Q được tính lại cho riêng hai khối của bộ A và trên tập con 563 tệp dài không quá 2 s (chuẩn hóa lại trên tập con này). Bảng 10 cho thấy khối phổ của A tách lớp tốt nhất, khối thời gian kém nhất, và thứ tự A $>$ C $>$ B không đổi khi bỏ các chuỗi dài. Như vậy, sự

Bảng 10: Tỷ số Q theo khối thuộc tính và theo tập tệp.

Biểu diễn	Số chiều	Q (655 tệp)	Q (563 tệp $\leq$ 2 s)
A, chỉ 5 thuộc tính thời gian	5	1,350	1,515
A, chỉ 16 thuộc tính phổ	16	1,927	1,979
A	21	1,735	1,782
B	39	1,376	1,368
C	60	1,473	1,505

tách lớp của bộ A chủ yếu đến từ các thuộc tính phổ, không phải từ cách cắt tệp. Ảnh hưởng của dạng bản ghi thể hiện ở chỗ khác: trong bộ A, 40 tệp hi-hat ngắn (không quá 2 s) có khoảng cách trong nhóm trung bình 0,479, 53 chuỗi hi-hat dài có 0,985, còn khoảng cách giữa hai nhóm là 1,481. Lớp hi-hat vì vậy tách thành hai cụm theo dạng bản ghi; một truy vấn là một tiếng hi-hat đơn sẽ có xu hướng gần các tệp hi-hat ngắn hơn là các chuỗi dài.

11.3 Ví dụ các cặp nhạc cụ

Bảng 11 cho hai loại khoảng cách giữa hai lớp. *Trung bình cặp* là trung bình khoảng cách mọi cặp tệp giữa hai lớp, nên bao gồm cả độ phân tán bên trong mỗi lớp. *Khoảng cách tâm* là $\|\bar{u}_c - \bar{u}_d\|_2$, với $\bar{u}_c$ là vector trung bình của lớp c; đại lượng này chỉ đo hai lớp lệch nhau bao xa. Trong bộ A, conga/tom gần nhau nhất (tâm cách 0,142), khớp với điểm chung giàu năng lượng thấp; kick/tambourine cách xa (1,508), khớp với khác biệt trầm/sáng. Trong bộ B, hi-hat/tambourine gần nhau hơn hẳn so với bộ A (0,413 so với 1,093): hai nhạc cụ có bao phổ dải cao tương tự dù độ phẳng khác nhau. Hai bộ vì vậy nhấn mạnh những mặt khác nhau của âm thanh.

Bảng 11: Khoảng cách giữa một số cặp lớp: trung bình cặp tệp (TB) và khoảng cách tâm lớp (Tâm).

	Bộ A		Bộ B		Bộ C	
Cặp nhạc cụ	TB	Tâm	TB	Tâm	TB	Tâm
conga / tom	0,487	0,142	0,952	0,391	0,769	0,294
kick / tom	0,789	0,461	1,062	0,566	0,974	0,516
snare / cymbal	0,996	0,450	0,941	0,417	0,986	0,434
hi-hat / tambourine	1,307	1,093	0,838	0,413	1,130	0,826
agogo / cowbell	0,923	0,635	2,013	1,396	1,586	1,084
marimba / vibraphone	0,923	0,304	2,148	0,836	1,661	0,629
kick / tambourine	1,642	1,508	1,188	0,780	1,450	1,200

Trung bình cặp marimba/vibraphone trong bộ B rất lớn (2,148) chủ yếu vì hai lớp này phân tán mạnh bên trong: khoảng cách trong lớp của marimba là 1,964 và của vibraphone là 2,097, cao nhất trong 13 lớp. MFCC thay đổi theo cao độ nốt được chơi, nên các nốt khác nhau của cùng một nhạc cụ nằm cách xa nhau. Xét khoảng cách tâm, lớp gần vibraphone nhất trong bộ B vẫn là marimba (0,836). Vì vậy, khi đánh giá độ giống nhau giữa hai lớp cần xem cả khoảng cách tâm và độ phân tán trong lớp.

12. Đóng góp của từng thuộc tính

12.1 Chỉ số phân biệt của từng thuộc tính

Với thuộc tính j, gọi μ_{cj}, σ_{cj}^2 là trung bình và phương sai trong lớp c. Chỉ số phân biệt được định nghĩa là

$$J_j = \frac{\mathrm{Var}_c(\mu_{cj})}{\frac{1}{13}\sum_c \sigma_{cj}^2},$$

dùng phương sai tổng thể, trọng số lớp bằng nhau và mẫu số chặn dưới ở 10^{-12}. J_j lớn nghĩa là trung bình của các lớp chênh nhau nhiều so với dao động bên trong lớp. Đây là chỉ số mô tả, không phải kiểm định thống kê hay lượng thông tin tính bằng bit. Kết quả cho thấy hình dạng bao phổ (MFCC 1), mức đổi dấu, độ phân

Bảng 12: Chín thuộc tính có J_j cao nhất trong 60 thuộc tính gốc của A và B.

Thuộc tính	Bộ	J_j
MFCC 1, trung bình	B	8,062
ZCR, trung bình	A	7,487
Entropy phổ, trung bình	A	7,145
Trọng tâm phổ, trung bình	A	7,107
Tần số cắt 85%, trung bình	A	6,709
Thông lượng phổ, trung bình	A	5,921
Độ rộng phổ, trung bình	A	4,591
Tỷ lệ năng lượng thấp, trung bình	A	4,217
Độ phẳng phổ, trung bình	A	3,900

tán và vị trí năng lượng có giá trị phân biệt cao nhất trên bộ dữ liệu, phù hợp với Bảng 10: cả chín thuộc tính đứng đầu đều thuộc khối phổ của bộ A (8 thuộc tính) hoặc MFCC (1 thuộc tính), không có thuộc tính nào của khối thời gian a_1–a_5. ZCR, trọng tâm và tần số cắt đều tăng khi âm có nhiều thành phần cao, nên chúng

không đóng góp độc lập với nhau. Một thuộc tính có J_j thấp vẫn có thể hữu ích cho một cặp lớp cụ thể hoặc khi kết hợp với thuộc tính khác.

12.2 Liên hệ với mục tiêu tìm tương đồng và khác biệt

Bảng 13: Vai trò của từng nhóm thuộc tính trong việc tìm âm tương đồng và tìm khác biệt.

Nhóm thuộc tính	Dùng để tìm tương đồng	Dùng để tìm khác biệt
Thời gian, hệ số đỉnh	Các tệp có cùng kiểu tập trung năng lượng, tính liên tục và bao âm.	Xung ngắn so với năng lượng kéo dài; đỉnh nhọn so với nền duy trì.
Trọng tâm, tần số cắt, L	Cùng giàu âm trầm hoặc cùng sáng.	Trống trầm so với các tiếng kim loại giàu tần số cao.
Độ rộng, độ phẳng, entropy phổ	Cùng phổ tập trung hoặc cùng phổ phân tán.	Cộng hưởng nổi bật so với phổ trải rộng; âm sáng có vạch so với âm sáng giống nhiễu.
ZCR, thông lượng phổ, các độ lệch chuẩn	Cùng mức dao động và biến đổi giữa các khung.	Phổ ổn định so với phổ đổi nhanh theo kích thích.
MFCC và delta	Cùng hình dạng bao phổ và mức biến thiên.	Phân bố năng lượng khác nhau dù trọng tâm hoặc năng lượng thấp tương tự.

13. Kết luận

13.1 Kết quả cho hai yêu cầu

Yêu cầu 1: bộ dữ liệu có 655 tệp WAV thuộc 13 nhóm nhạc cụ bộ gõ, vượt mức tối thiểu 500 tệp, được sưu tầm từ ba nguồn công khai và đều đạt các tiêu chuẩn chất lượng ở Mục 2. Báo cáo mô tả nguồn, cách gán nhãn, tiêu chí tuyển chọn, định dạng, số lượng và thời lượng từng nhóm. Điểm giống và khác nhau giữa các nhạc cụ được giải thích theo cách tạo âm, minh họa bằng phổ đồ và đối chiếu bằng số đo trên dữ liệu thực tế.

Yêu cầu 2: ba bộ đặc trưng A (21 chiều), B (39 chiều) và C (60 chiều) đã được xây dựng và tính cho toàn bộ 655 tệp. Mỗi thuộc tính có định nghĩa, công thức, thông tin mang lại và giới hạn diễn giải. Vector chuẩn hóa cùng khoảng cách Euclid cho phép đo mức tương đồng và khác biệt một cách nhất quán giữa các tệp có độ dài khác nhau. Trên bộ dữ liệu hiện tại, bộ A tách lớp tốt nhất theo tỷ số Q, chủ yếu nhờ các thuộc tính phổ; bộ B và C bổ sung thông tin về hình dạng bao phổ.

13.2 Giới hạn

- **Dạng bản ghi và cân bằng lớp:** 92 tệp là chuỗi nhiều lần gõ, làm lớp hi-hat tách thành hai cụm; số tệp giữa các lớp chênh lệch từ 11 đến 151. 655 tệp không tương ứng với 655 phiên thu độc lập.
- **Phạm vi kết luận:** các số liệu là phân tích mô tả trên toàn bộ dữ liệu, chưa phải độ chính xác nhận diện trên dữ liệu mới. Khoảng cách giữa lớp có thể phản ánh một phần khác biệt về nguồn thu, kỹ thuật chơi và cách trích đoạn; trung vị của lớp không phải đặc tính cố định của nhạc cụ ngoài thực tế.

13.3 Hướng hoàn thiện

1. Tách các chuỗi IDMT thành từng tiếng gõ đơn bằng phát hiện khởi âm (onset), bổ sung mẫu cho các lớp ít dữ liệu và kiểm tra các bản thu gần trùng.
2. Thử bổ sung thuộc tính độ hài hòa cho các nhạc cụ có cao độ.
3. Khi đánh giá nhận diện, chia tập học và tập kiểm tra theo bản thu gốc để tránh các đoạn gần nhau rơi vào cả hai tập; chỉ ước lượng tham số chuẩn hóa từ tập học và báo cáo kết quả theo từng lớp.

13.4 Kiểm tra tính toán

Tất cả vector A, B và C có đủ số chiều và chỉ chứa giá trị hữu hạn; mã băm đầu vào khớp hồ sơ kiểm kê. Không có tệp nào chỉ có một khung phổ hợp lệ hoặc thiếu hoàn toàn cửa sổ hợp lệ để tính delta. Các kiểm tra triển khai đã đạt: đặc trưng không đổi khi thay đổi mức khuếch đại, và âm sin trầm có tỷ lệ năng lượng thấp cao hơn, độ phẳng thấp hơn nhiễu trắng.

Môi trường tính đặc trưng dùng NumPy 2.4.6, SciPy 1.17.1 và SoundFile 0.13.1. Các số trong bảng đã được làm tròn khi trình bày. Tham số chuẩn hóa μ_j, s_j và chương trình trích xuất được nhóm giữ lại để tính vector cho âm thanh truy vấn theo đúng quy ước này ở các yêu cầu tiếp theo.

Phụ lục: danh sách thuộc tính của các bộ đặc trưng

Bảng 14 liệt kê đầy đủ các chiều của bộ A và bộ B theo đúng thứ tự trong vector. Bộ C gồm 21 chiều của A (sau chuẩn hóa, chia cho $\sqrt{42}$) nối tiếp 39 chiều của B (sau chuẩn hóa, chia cho $\sqrt{78}$), tổng cộng 60 chiều (Mục 10). "TB" là trung bình và "ĐLC" là độ lệch chuẩn trên các khung hợp lệ của tệp.

Bảng 14: Các thuộc tính của bộ A (21 chiều) và bộ B (39 chiều).

Chiều	Thuộc tính	Ký hiệu	Đơn vị	Định nghĩa
Bộ A: 5 thuộc tính thời gian				
A1	Thời gian có tín hiệu (log)	a_1	–	$\ln(1 + T_a)$, Mục 7
A2	Khoảng chứa 90% năng lượng (log)	a_2	–	$\ln(1 + D_{90})$
A3	Hệ số đỉnh	a_3	dB	Đỉnh so với RMS vùng có tín hiệu
A4	Tỷ lệ có tín hiệu	a_4	–	T_a/T_s
A5	Vị trí đỉnh bao RMS	a_5	–	Vị trí tương đối trong vùng có tín hiệu
Bộ A: 16 thuộc tính phổ (TB và ĐLC của 8 đại lượng)				
A6–A7	Trọng tâm phổ	C	Hz	Mục 8
A8–A9	Độ rộng phổ	W	Hz	
A10–A11	Tần số cắt 85%	R	Hz	
A12–A13	Độ phẳng phổ	F	–	
A14–A15	Entropy phổ	H	–	
A16–A17	Tỷ lệ đổi dấu	Z	–	
A18–A19	Tỷ lệ năng lượng dưới 500 Hz	L	–	
A20–A21	Thông lượng phổ dương	Φ	–	
Bộ B: 39 thuộc tính MFCC				
B1–B13	TB của MFCC 1 đến 13	$c[1..13]$	–	Mục 9
B14–B26	ĐLC của MFCC 1 đến 13	$c[1..13]$	–	
B27–B39	ĐLC của delta MFCC 1 đến 13	$\Delta c[1..13]$	–	

Tài liệu tham khảo

[1] A. Ramires, P. Chandna, X. Favory, E. Gómez và X. Serra. *Freesound One-Shot Percussive Sounds*, Version 1.0, Zenodo. DOI: 10.5281/zenodo.4687854. `https://zenodo.org/records/4687854`.

[2] Fraunhofer IDMT. *IDMT-SMT-Drums*. `https://www.idmt.fraunhofer.de/en/publications/datasets/drums.html`. Gói dữ liệu: `https://zenodo.org/records/7544164`.

[3] L. Fritts, University of Iowa Electronic Music Studios. *Musical Instrument Samples*. `https://theremin.music.uiowa.edu/MIS.html`.

[4] Y. Wu, K. Chen, T. Zhang, Y. Hui, T. Berg-Kirkpatrick và S. Dubnov. Large-scale contrastive language-audio pretraining with feature fusion and keyword-to-caption augmentation. *Proc. IEEE ICASSP*, 2023. Mô hình `laion/clap-htsat-unfused`: `https://huggingface.co/laion/clap-htsat-unfused`.

[5] S. B. Davis và P. Mermelstein. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 28(4):357–366, 1980.

[6] G. Peeters. *A large set of audio features for sound description (similarity and classification) in the CUIDADO project*. Báo cáo kỹ thuật, IRCAM, 2004.

[7] SciPy Developers. *scipy.fft.dct*. `https://docs.scipy.org/doc/scipy/reference/generated/scipy.fft.dct.html`. Phiên bản SciPy dùng khi tính dữ liệu: 1.17.1.